

Edge-Cloud 아키텍처 디자인

WEEK 1

Edge-Cloud 아키텍처 디자인 소개

■ 스터디 목표

- Edge-Cloud 아키텍처를 이해하고, 개인의 도메인/비즈니스에 맞는 아키텍처를 직접 설계
- 최종 산출물: 논리 아키텍처 + 물리 아키텍처

■ 커리큘럼

	주제	세부 내용
WEEK 1	Kickoff Meeting	▪ OT ▪ Edge-Cloud 소개
WEEK 2	Edge-Cloud 개념 및 사례 소개	▪ Edge Computing 소개 ▪ Cloud 역할 ▪ 생태계와 기술 스택 ▪ Use Case
WEEK 3	개인 주제 선정	▪ 도메인/비즈니스 선정 및 Ref. 조사 ▪ Edge/Cloud의 역할 분해
WEEK 4	논리 아키텍처 설계	▪ 논리 아키텍처 설계 및 공유
WEEK 5	논리 아키텍처 설계	▪ 논리 아키텍처 설계 및 공유
WEEK 6	물리 아키텍처 설계	▪ 물리 아키텍처 설계 및 공유 ▪ Infra, N/W, Application
WEEK 7	물리 아키텍처 설계	▪ 물리 아키텍처 설계 및 공유 ▪ Infra, N/W, Application
WEEK 8	아키텍처 구현	▪ 최종 아키텍처 상호 리뷰 ▪ 구현 공유

Edge-Cloud 아키텍처란


- **Cloud 한계:** 무제한 컴퓨팅 리소스를 제공하지만, 모든 워크로드가 클라우드에서 처리될 수는 없음
 - **실시간 응답:** 실시간 응답이 필요한 상황에서 왕복 100ms 이상 응답은 치명적임 (예: 자율주행, 로봇 등 ~10ms 판단)
 - **대용량 데이터 발생:** 모든 데이터를 클라우드로 전송하는 경우 네트워크 비용과 대역폭 감당 불가 (예: 스마트팩토리 TB/h ~PB/h 규모)
 - **불안정한 네트워크:** 오프라인 환경에서 서비스가 동작해야 하는 경우 (예: 선박, 원격지...)
 - **데이터 보안:** 규제/데이터 보안으로 인해 현장에서 벗어나면 안되는 경우
- **Edge Computing:** 데이터가 발생하는 현장(Edge)에서 연산을 수행하는 패러다임
 - 메모리, 스토리지, GPU 등 제한적
 - 대규모 학습, 글로벌 분석, 장기 데이터 보관은 Cloud가 적합
 - 여러 Edge를 관리하기 위해서는 Cloud가 필수적

Use Case

도메인	Edge	Cloud
자율주행	주행 판단, 데이터 실시간 추론	주행 데이터 수집, 모델 재학습, Over-The-Air 배포
Smart Factory	비전 검사, 설비 이상 감지	공정 간 통합 분석, 모델 배포
미디어/CDN	사용자 인접 캐싱	원본 저장, 글로벌 배포 관리
통신/네트워크	기지국 트래픽 관리	전체 네트워크 관리 - Core



논리 아키텍처

시스템의 기능적 요소와 관계를 표현



물리 아키텍처

논리 아키텍처를 실제 인프라에 매핑 - AWS, Azure, GCP, On-prem 등 기술 선택



Edge-Cloud Introduction

WEEK2

Edge-Cloud 계층 구조

데이터가 발생하는 Edge와 고성능 연산이 가능한 Cloud를 연결하여, 각 계층의 장점(저지연성/고성능)을 극대화한 구조

Cloud

- **전체 중앙 시스템으로 무거운 연산과 전체 Orchestration을 담당**
- **구성:** Public Cloud (AWS, Azure, GCP), Hybrid Cloud
- **핵심 역할**
 - AI/ML 모델 학습 및 버전 관리
 - Edge Node Orchestration: 배포, 모니터링, 정책, 버전 관리
 - 장기 데이터 저장, 분석, 리포팅
- **핵심 기술**
 - Kubernetes
 - MLOps Pipeline
 - DataLake

Edge


- **Cloud와 Device 사이 중간 지점으로, 저지연 실시간 처리**
- **구성:** Edge Server, 기지국(MEC)
- **핵심 역할**
 - 실시간 추론 (ms 단위 응답)
 - 데이터 전처리, 집계 후 클라우드 전송
 - 클라우드 장애 시, 자율 동작 (Offline Resilience)
- **주요 하드웨어**
 - NVIDIA Jetson

Device

- **데이터가 발생하는 레이어로 수집과 1차 처리 담당**
- **구성:** IoT 센서, 스마트폰, 카메라, 로봇, 차량
- **핵심 역할**
 - Raw 데이터 수집 및 Sampling
 - 엣지로 필요한 데이터 선별 전송
- **통신 프로토콜**
 - MQTT, BLE, Zigbee, LTE/5G

Edge-Cloud 계층 구조


데이터가 발생하는 Edge와 고성능 연산이 가능한 Cloud를 연결하여, 각 계층의 장점(저지연성/고성능)을 극대화한 구조



- **Northbound Interface: Device/Edge → Cloud**
- **데이터 수집:**
 - 센서 Raw 데이터 수집
 - 이상치/노이즈 필터링
 - Semantic 데이터 선별
- **모델 추론:**
 - 추론 결과, 예측 오류, 이상치 감지
- **상태 보고:**
 - 노드 상태, 리소스 사용량, 이벤트 로그
- **Southbound Interface: Cloud → Edge/Device**
- **모델 배포:**
 - 학습 모델/모델셋 배포 (OTA, Container Image)
- **정책 배포:**
 - Threshold, 데이터 수집 대상, 샘플링 주기
- **스케줄링:**
 - 시스템 제어, 작업 할당 등

Edge-Cloud 기술 생태계

Cloud에서 컨테이너화 된 애플리케이션 배포/확장/관리



- **Cloud Orchestration: Kubernetes (K8S)**
- **Edge Orchestration:** 리소스가 제한된 환경에서 K8S 역할을 대체하는 경량 오케스트레이션
 - **K3S:** K8S를 경량화한 독립 실행 클러스터 (Rancher 개발)
 - **KubeEdge:** K8S를 Edge까지 확장하는 구조 (Huawei 개발 – CNCF)
- **Message Queue: Edge-Cloud 비동기 데이터 파이프라인을 구성하는 메시지 미들웨어**
 - **Apache Kafka:** Producer → Topic → Consumer 구조로, 높은 처리량, 메시지 영속성, 재처리 가능
 - **RabbitMQ:** 유연한 라우팅
 - **Mosquitto:** 저전력 디바이스 특화
 - **NATS:** 초저지연, Edge 경량 브로커
- **Data Lake: Edge의 원시 데이터 등 모든 형태의 데이터를 클라우드에 저장하기 위한 저장소**
 - Edge에서 필터링/집계된 데이터를 클라우드에 적재
 - 정형/비정형 데이터 모두 저장하여 AI 학습에 필요한 원시 데이터를 활용할 수 있도록 함

Edge-Cloud Application – Real-time Analytics & Inspection

제조/물류 현장에서 ms 단위 판단이 필요한 품질 검사 및 이상 탐지를 Edge에서 처리


▪ Edge 역할:

- Cloud 왕복 Latency는 제조 라인 속도 따라갈 수 없음
- 불량 원본 이미지를 Cloud 전송 시 N/W Bandwidth 비용

▪ Vision 검사 구성: Vision Camera – Edge Server – Cloud

▪ 사례

- Vision 검사 (Battery, X-ray 등)
- 반도체 장비 데이터 검사
- 물류 라벨/바코드 검사/검출



Edge-Cloud Application – IoT (Smart Factory, Predictive Maintenance)

수천 개의 현장 센서 데이터를 Edge에서 실시간 분석하여 장비 고장을 사전 예측하여 생산 효율 극대화

▪ Edge 역할:


- 공장 내 센서가 GHz 데이터 생성 시, Cloud 전송 불가
- N/W 장애 시에도 공장은 지속 생산 필요 (Offline Resilience)

▪ 핵심 구성:

- 진동/온도/전류/압력 등 Sensor, PLC 등
- Edge: 이상 패턴 감지
- Cloud: 장기 트렌드 분석, 예지 정비, Digital Twin

▪ 사례

- 모터/베어링 진동 이상 감지
- 전력 소비 패턴을 통한 에너지 비용 최적화
- Digital Twin



Edge-Cloud Application – 자율 주행

차량 (온디바이스)과 클라우드가 협력하여 안전/효율적인 자율주행 실현

▪ Edge 역할:


- 충돌 판단 (~10ms)로 클라우드 왕복 불가
- 차량 1대 당 ~GB/s 데이터 생성

▪ 핵심 구성:

- Edge: 제동/조향 판단, 장애물 회피
- Cloud: Map 업데이트, 주행 판단 학습

▪ 사례

- 모



Edge-Cloud Application – Healthcare

환자 생체 데이터를 Edge에서 실시간 모니터링 후, 응급 상황을 즉시 감지

▪ Edge 역할:


- 환자 데이터는 개인정보 규제로 클라우드 전송 제한
- Device 데이터 전량 클라우드 전송 시 비용/보안 문제 발생

▪ 핵심 구성:

- 웨어러블, 의료 장비 등
- 이상 바이탈 감지, 알람, 의료 영상 1차 판독
- 장기 환자 데이터 분석, 임상 연구 데이터

▪ 사례

- 웨어러블 심전도 → 부정맥 실시간 감지
- CT/MRI 영상 Edge 1차 판독



Edge-Cloud Application – Robot Fleet Management

수백 대의 로봇을 Edge에서 실시간 조율하고, Cloud에서 전체 Fleet 최적화

▪ Edge 역할:


- 로봇 간 충돌 회피, 경로 조율 ~10ms이내 결정 필요
- N/W 장애 시에도 로봇 작동 필요

▪ 핵심 구성:

- 로봇은 개별 장애물 회피, 로컬 센서 처리, 제어 등
- 전체 작업 최적화 (Task allocation), 성능 분석
- 모델 업데이트 배포

▪ 사례

- AGV, AMR Fleet Management
- AGV 경로 최적화
- Drone 군집 제어
- 배송 로봇 운영



Edge-Cloud Application – MEC (Multi-access Edge Computing)

통신사 기지국 (5G RAN) 옆에 컴퓨팅 자원을 배치하여 초저지연 네트워크 인프라 제공 (Edge Computing 인프라 레벨)

▪ Edge 차이점:


- 통신사 기지국 운영
- LTE/5G 연결로 1~5ms 초저지연
- 이동 단말 Handover 지원

▪ 핵심 구성:

- 3GPP 5G 표준으로 MEC N/W Slicing
- UPF (User Plane Function)으로 Edge 처리

▪ 사례


- 공연장/스타디움 실시간 스트리밍
- Smart City CCTV, 자율주행(V2X)




Edge-Cloud Model – Cloud Training & Edge Inference

- **개념: Training/Inference를 물리적으로 분리**
 - 모델 학습은 GPU/데이터 리소스 필요하여 Cloud 수행
 - Model Registry를 통해 Artifact 저장소로 버전 관리
 - OTA (Over-the-Air) 배포로 Edge에 무중단 업데이트
- **핵심 구성:**
 - Cloud: 데이터셋 생성, 모델 학습/검증/평가, 모델 Registry 등록
 - Edge Pipeline: Container 패키징, Rolling 배포
 - Edge: Inference 결과, 성능 모니터링
- **사례**
 - 제조 검사 모델을 클라우드에서 재학습하여 배포
 - 자율주행 OTA 업데이트


Edge-Cloud Model – Quantization & Pruning



Quantization: Weight 데이터 타입을 줄여 모델 크기/연산량 감소



Pruning: 중요도가 낮은 가중치를 제거





Knowledge Distillation: 큰 모델 (Teacher)가 작은 모델(Student) 모델로 지식 증류

Edge-Cloud Model – Federated Learning

■ 개념:

- Edge에서 수집된 데이터로 모델 개별 학습
- Gradient만 클라우드 전송
- Cloud에서 Global 모델 aggregate 하여 모델 재배포



https://encyclopedia.pub/media/item_content/202308/64eed7be5abe3futureinternet-15-00203-g002.png

Edge-Cloud Model – Hybrid Inference




Figure 10: Overview of Neurosurgeon. At deployment, Neurosurgeon generates prediction models for each layer type. During runtime, Neurosurgeon predicts each layer's latency/energy cost based on the layer's type and configuration, and selects the best partition point based on various dynamic factors.

Kang et al, "Neurosurgeon: Collaborative Intelligence Between the Cloud and Mobile Edge", ACM 2017

Split Inference: 모델 레이어를 Edge/Cloud 분할 배치





Fig. 4. Illustration of three execution-phase task-division strategies: (a) request routing, dispatching queries to optimal LLM experts based on semantics and cost; (b) task offloading, splitting computation graphs across edge and cloud for cost-aware load balancing; and (c) early exit, multi-exit networks that terminate early for simple inputs to reduce latency and energy.

Early Exit: 쉬운 입력은 앞 레이어에서 조기 종료



Speculative Decoding: Edge Draft 모델, Cloud 모델 토큰 검증

Edge-Cloud Agent

8 • Senyao Li, Haozhao Wang, Wenchao Xu, Rui Zhang, Song Guo, Jingling Yuan, Xian Zhong, Tianwei Zhang, and Ruixuan Li




Fig. 3. Comparison of task assignment in edge-cloud systems: (a) Agents decompose user instructions to multi-stage plans executed by specialized agents; (b) MoE-based selection and fusion of top- k cloud LLM experts via fine-grained gating.

Edge-Cloud Agent Architecture

- SLM이 간단한 쿼리를 처리 - System1 Thinking
- LLM이 복잡한 Task 처리 - System2 Thinking





Fig. 6. Hybrid SLM-LLM collaboration in RAG: the SLM encodes queries and retrieves documents via approximate nearest-neighbor search, and the LLM generates responses using the query and retrieved context.

SLM-LLM RAG Pipeline

- SLM: 쿼리에 대한 문서 검색
- LLM: 선택된 문서와 쿼리를 받아 최종 응답 생성

[USECASE 1] 자율주행

- Tesla Shadow Mode

- Edge - 자율주행 차량

- **Shadow Inference:** 실제 주행 모델(Production) 뒤에서 신규 모델(Shadow)이 실시간으로 동시 추론 수행
- **Trigger-based Harvesting:** 운전자의 갑작스러운 개입, 모델 간 예측 불일치 발생 시, 해당 시점 데이터 캡처
- **Data Efficiency:** 모든 데이터를 전송하는 대신, 주요한 데이터만 필터링하여 통신 및 클라우드 부하 최소화

- Cloud – Dojo (AI 훈련 전용 서버)

- **Fleet Learning:** 수백만 대의 Edge(차량)로부터 수집된 불일치 데이터를 통합하여 중앙 거대 모델 재학습
- **Auto-Labeling:** 클라우드의 GPU 인프라를 활용하여 수집된 데이터에 대한 자동 라벨링 및 시뮬레이션 데이터 생성
- **OTA (Over-the-Air) Deployment:** 검증이 완료된 최신 모델을 Edge(차량)으로 무선 배포하여 성능 상향 평준화



[USECASE 2] 리테일

- Amazon Go
- Edge – Store (매장)
 - **Visual Odometry:** 수백 개의 Edge 카메라가 고객의 이동 경로를 실시간 추적
 - **Sensor Fusion:** 카메라 영상과 선반의 무게 센서를 이용해 결제 리스트 실시간 생성
 - **Action Recognition:** 제품을 집고 내려놓는 동작을 ms 단위로 판정하여 지연 시간 제거
- Cloud – AWS
 - **Asynchronous Billing:** 고객이 매장을 나가는 즉시 영수증 발행 및 결제 처리
 - **Global Optimization:** 각 지점의 실시간 재고 상태를 취합하여, 물류 최적화 및 수요 예측
 - **Continuous Learning:** Edge에서 잘못된 판정에 데이터만 Cloud로 전송해 AI 모델 재학습



-
- 개인별 관심 도메인 설정 및 정리
 - 해당 도메인/기술 현재 구조 현황